УДК 534.843:004.9

Задорожний М.О., Крак Ю.В.

Київський національний університет імені Тараса Шевченка

ПІДВИЩЕННЯ ГЕНЕРАЛІЗАЦІЇ МОДЕЛІ РОЗПІЗНАВАННЯ ДАКТИЛЕМ УКРАЇНСЬКОЇ ЖЕСТОВОЇ МОВИ В УМОВАХ ОБМЕЖЕНИХ ДАНИХ

Розглянуто підхід до підвищення генералізації моделей глибокого навчання при розпізнаванні дактилем української жестової мови за умов обмеженої кількості даних. Запропоновано використання архітектури X3D-M, попередньо навченої на масштабних відеодатасетах, що забезпечує стабільність розпізнавання та зменшує ризик перенавчання. Експерименти показали точність класифікації до 91% F1-score при значній стійкості моделі до варіацій фону та положень руки.

An approach to improving the generalization capability of deep learning models for Ukrainian sign language fingerspelling recognition under limited data conditions is presented. The use of the X3D-M architecture pre-trained on large-scale video datasets is proposed, providing stable recognition and reduced overfitting. Experiments demonstrated classification quality up to 91% F1-score and significant robustness to variations in background and hand position.

Актуальність автоматичного розпізнавання української жестової мови (УЖМ) зумовлена потребою забезпечення рівного доступу до інформації та комунікації для людей із порушеннями слуху, які щоденно стикаються з бар’єрами у взаємодії з чуючими людьми та цифровими сервісами. В Україні тисячі нечуючих громадян використовують жестову мову як основний засіб спілкування, проте через відсутність стандартних технологічних рішень ефективна комунікація з оточуючими часто ускладнена. Розробка систем автоматичного розпізнавання УЖМ дозволяє перекладати жести у текст або мовлення в реальному часі, відкриваючи нові можливості для освіти, медіа, державного обслуговування та соціальної взаємодії.

Автоматичне розпізнавання жестів є складною задачею через значну варіативність положень і рухів руки, а також змінність умов освітлення та фону. Попередні підходи, що базувалися на класичних методах комп’ютерного зору (HOG[1], «мішок ознак»[2], розділення гіперплощинами[3]), виявилися надто чутливими до змін середовища.

Використання згорткових нейромереж значно підвищує стійкість до зовнішніх факторів, проте потребує масштабних навчальних

вибірок. Для української жестової мови відчувається значний дефіцит датасетів, а тому більшість наявних моделей навчені на недостатньо репрезентативних вибірках та демонструють ефективність лише в контрольованих умовах, втрачаючи точність при роботі з реальними відео.

Тому метою даної роботи є розробка легкої моделі глибокого навчання для розпізнавання дактилем української жестової мови з фокусом на підвищенні генералізації при нестачі навчальних даних.

У роботі використано архітектуру X3D-M, що є складовою сімейства моделей Expand 3D[4], розробленого Facebook AI Research. Ключовою особливістю сімейства є поступове та оптимізоване розширення по 3D-простору, що забезпечує високу ефективність відеорозпізнавання при помірних обчислювальних витратах.

Усі моделі Expand 3D, включаючи X3D-M, навчалися з нуля на датасеті розпізнавання дій людини Kinetics-400[5], без використання ImageNet опори. Kinetics-400 містить близько 240 тисяч навчальних, 20 тисяч валідаційних та 35 тисяч тестових відео, що охоплюють 400 класів людських дій. Тренування виключно на відеоданих застосовано щоб уникнути упередженості від статичних зображень і отримати «чистіше» навчання саме для відеоаналізу.

Для донавчання на потрібний домен використано модифіковану версію датасету[6] українських дактилем, розширену до понад 3000 відео (Рис.1). Аугментації проводилися «на льоту», включають обрізання з масштабуванням, повороти, зміни яскравості, контрасту, насиченості, відтінку, додання розмиття та шумів.

Рисунок 1 – демонстрація навчальної вибірки, фрейми

Результати показали покласово середнє top-1 F1-score приблизно рівним 91% на тестовій вибірці (рисунок 2). Найкраще розпізнаються жести з чіткими візуальними відмінностями, тоді як подібні форми рук потребують додаткової генералізації навчальних прикладів.

Рисунок 2 – демонстрація тестової вибірки, фрейми

Отримані результати ставлять застосування архітектури X3D-M та навчання з перенесенням як перспективну стартову точку для задачі розпізнавання дактилем української жестової мови в умовах малої кількості даних. Подальші дослідження спрямовуватимуться на розширення навчального набору, використання генеративних моделей для синтетичних даних та підвищення стабільності класифікації жестів.

Перелік посилань

1. Prasuhn L., Oyamada Y., Mochizuki Y., Ishikawa H. Система розпізнавання жестів руки на мобільному пристрої на основі HOG. Proc. IEEE Int. Conf. on Image Processing (ICIP). 2014. С. 3973–3977. DOI: https://doi.org/10.1109/ICIP.2014.7025807
2. Dardas N. H., Georganas N. D. Виявлення та розпізнавання жестів руки в реальному часі з використанням методу «мішок ознак» і техніки опорних векторів. IEEE Transactions on Instrumentation and Measurement. 2011. Т. 60, № 11. С. 3592–3607. DOI: https://doi.org/10.1109/TIM.2011.2161140
3. Krak I., Kudin G., Kulias A. Багатовимірне масштабування за допомогою псевдообернених операцій. Cybernetics and Systems Analysis. 2019. Т. 55, № 1. С. 22–29. DOI: https://doi.org/10.1007/s10559-019-00108-9
4. Feichtenhofer C. X3D: Розширення архітектур для ефективного розпізнавання відео. Proc. IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR). 2020. С. 203–213. DOI: https://doi.org/10.1109/CVPR42600.2020.00028
5. Kay W., Carreira J., Simonyan K., Zhang B., Hillier C., Vijayanarasimhan S., Viola F., Green T., Back T., Natsev P., Suleyman M., Zisserman A. Набір даних відео людських дій Kinetics Human Action Video Dataset. 2017. URL: https://arxiv.org/abs/1705.06950
6. Kondratiuk S., Krak I., Kuznetsov V., Kulias A. Використання часових даних і тривимірних згорток для розпізнавання абетки жестової мови. Proc. CMIS 2022 : зб. наук. пр. за матеріалами конф. 2022. С. 78–87. DOI: https://doi.org/10.32782/cmis/3137-7